15.1 扩展：信息熵

15.1.1 从直觉到数学概念

你感觉一下以下两个场景。

（1）你站在撒哈拉沙漠的中心。我问你：“你觉得明天是什么天气?”你几乎不用思考，会笑着回答：“这还用问？大晴天呗。”是啊，在那种地方，你对“明天天气”这件事，心里是**十拿九稳**的。几乎没有不确定性，因为根据地理常识，撒哈拉几乎不下雨。

（2）你现在到了春城昆明或者伦敦。同样的，我问你：“你觉得明天是什么天气?”你可能要挠头了。早上可能阳光明媚，午后可能一阵急雨，傍晚又可能云开雾散。你心里会犯嘀咕：“这还真不好说。”你对“明天天气”这件事，感觉**捉摸不定**。不确定性很大。

你看，还没用任何一个数学符号，你已经真切地体会到了什么是“不确定性”，以及它在不同情境下有多少之分。

再举个更生活化的例子。想象三个同学在篮球场练习罚球。

- **小明**是校队主力，投篮命中率高达 90%。他没出手前，你心里就会有个强烈的预期：“嗯，这个球，**大概能进**。”
- **小刚**是个普通爱好者，命中率为 50%。他举起球时，你心里完全没底：“这个一半一半吧，猜不准。”
- **小王**最近手受伤了，命中率只有 10%。他准备投篮时，你同样会有一个强烈的预期：“哎，**估计进不了**。”

发现了吗？对于小明和小王，虽然一个大概率进，一个大概率不进，但你对他们**单次投篮结果**的“把握感”是类似的——都很强。唯独对小刚，你是最“拿不准”的。这种“拿不准”的程度，就是我们想用数学来捕捉的东西。

最后，我们玩一个扑克牌游戏。我从一副洗好的 54 张牌里，随机抽一张给你看。在抽之前，我给你以下两种猜法。

- **猜法 A**：你猜这张牌是“红色”还是“黑色”。
- **猜法 B**：你猜这张牌是“大王”还是“不是大王”。

你选哪个来赌？凭直觉，你会觉得猜法 A 更难，对吧？因为红黑对半开，结果非常难预测。而猜法 B 呢？你几乎可以肯定抽到的是“不是大王”（概率 $53/54 \approx 98.1\%$），只有很小的可能（1/54）是惊喜。

好，直觉热身到此为止。我们感受到了“不确定性”像温度一样，有高有低。那么，作为一个严谨的学科，我们不可能永远停留在“感觉拿不准”这种描述上。我们必须回答以下两个问题。

（1） **如何精确地度量这种“不确定程度”?**

（2） **度量出来的这个“数”，它到底意味着什么?**

这就是“信息熵”要解决的全部问题。

15.1.2 从“不确定性”到“信息量”

要度量“不确定性”，我们需要一个更小的砖块。这个砖块叫作**信息量**。

我们这样想：什么情况下，你会觉得自己“获得了信息”？答案是：当一件原本你不确定的事情，结果揭晓了，你的不确定性被消除了。这个消除的过程，就伴随着信息的获取。

所以，**信息的作用，就是消除不确定性。**获得的信息越多，消除的不确定性就越大。

那么下一个问题：是不是所有“结果揭晓”带给你的信息都一样多呢？我们回到刚才的例子。

- 在撒哈拉沙漠，有人郑重其事地告诉你：“明天是晴天。”你听了会有什么反应？你可能会觉得这是一句废话，因为它几乎没有消除你任何不确定性——你本来就几乎 100% 确定是晴天。这句话带来的信息量微乎其微。
- 但是，如果他在撒哈拉沙漠告诉你：“明天要下暴雨！”你会是什么反应？你大概率会跳起来，认为这是一个爆炸性的、惊人的消息！因为它彻底颠覆了你原有的、近乎确定的认知。这句话带来的信息量巨大。

发现规律了吗？**单个事件发生所带来的信息量，与其发生的概率成反比。**事件越是出乎意料（概率小），当它真的发生时，带给你的信息量就越大；事件越是在预料之中（概率大），发生时带给你的信息量就越小。通俗来说，**越稀奇的事儿，信息量越大；越是废话，信息量越小。**

这个直觉太重要了。我们再用篮球的例子巩固一下。小王的命中率只有 10%。

- 如果他没投进（90% 的概率），你感觉如何？“哦，果然没进。”——信息量很小。
- 如果他居然投进了（10% 的概率），你感觉如何？“哇！这都能进！”——信息量巨大。

所以，信息量 $I(x)$ 应该是事件发生概率 $p(x)$ 的递减函数：$p(x)$ 越大，$I(x)$ 越小。

15.1.3 可加性的自然要求

那么，具体用什么函数呢？$I(p) = 1/p$？或者 $I(p) = -p$？我们得找一个符合我们深层直觉的函数。

考虑一个经典场景：你抛一枚**绝对公平的硬币**两次。第一次抛出正面，第二次抛出反面。请问“正-反”这个联合结果，带给你的总信息量是多少？

直觉上，两次独立抛掷的结果应该是互不干扰的。知道第一次是正面，并不影响你对第二次的猜测（还是 50% 对 50%）。所以，两次抛掷带来的总信息量，应该等于第一次抛掷的信息量加上第二次抛掷的信息量。

这就引出了我们对信息量函数的第二个，也是更关键的要求：**对于独立事件，信息量应具备可加性。**

如果事件 A 和事件 B 独立，那么它们同时发生的概率是 $p(A \cap B) = p(A) \cdot p(B)$。我们要求：

$$I(p(A) \cdot p(B)) = I(p(A)) + I(p(B))$$

什么样的函数，能把“乘法”转换成“加法”呢？别去翻复杂的数学公式，想想你在高中时学过，算乘法太麻烦时，数学家是怎么偷懒的？对，他们发明了对数。

对数唯一的超能力，就是把乘法降级成加法。我们正好需要这个——既然独立事件的概率是相乘变得极小，那我们就用对数把它拉回来，变成简单的相加。

对数函数中，有 $\log(a \cdot b) = \log(a) + \log(b)$。所以，我们很自然地做如下定义。

$$I(x) = \log\left(\frac{1}{p(x)}\right) = -\log(p(x))$$

这里有个负号，因为 $p(x) \leq 1$，所以 $\log(p(x)) \leq 0$。加个负号，就确保了信息量 $I(x) \geq 0$。概率越小，$1/p(x)$ 越大，其对数值也越大，信息量就越大。完全符合直觉。信

息量与概率的关系曲线可以直观地从图15-1中看到：蓝色点表示小概率事件发生时，会产生极大的信息量（惊喜度）；黑色点表示必然事件，信息量归零。即小概率事件发生时信息量巨大，而必然事件的信息量为 0。

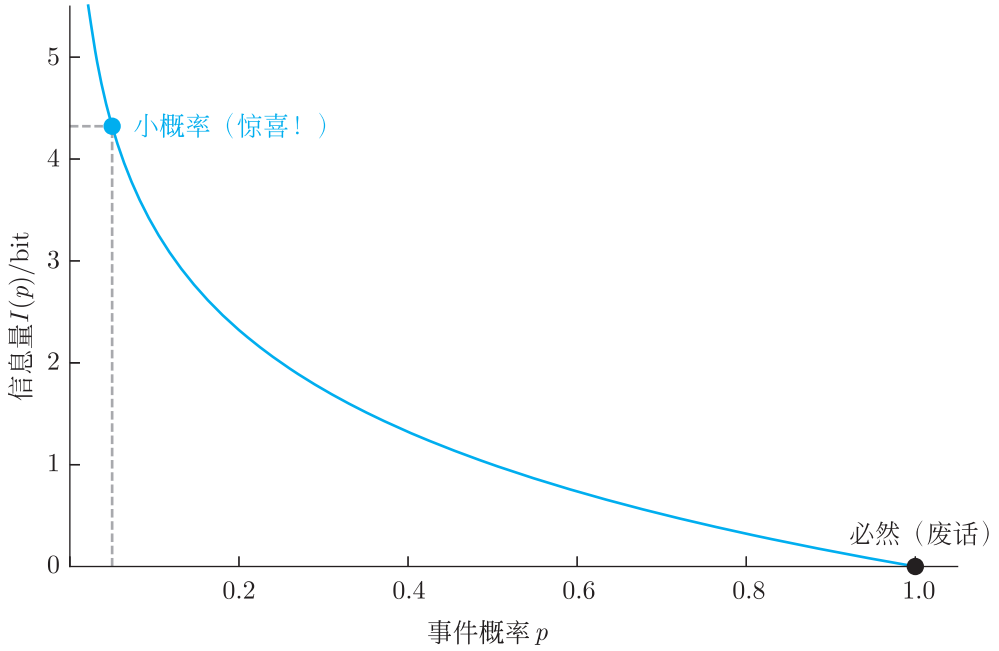


图 15-1: 信息量与概率的关系曲线

15.1.4 比特：信息量的单位，以及为什么底数是 2

最后一个技术选择：对数的底。我们为什么常用以 2 为底呢?

这其实就是咱们小时候玩的“猜数字”。如果我让你在 1 到 8 之间猜个数字。如果一个个问“是 1 吗? 是 2 吗?”，效率太低了。

聪明人直接一刀切：“大于 4 还是小于等于 4?”这一刀下去，你就排除了一半的错误答案。这就叫获取了 1 bit 的信息。

这种“一刀切”的高效搜索过程，在图15-2中以二分搜索树清晰地展示了出来。通过三次是/否提问（如“大于 4 吗?”）可以从 8 个等可能选项中确定一个具体数字，这恰好需要 $\log_2 8 = 3$ bit 的信息。

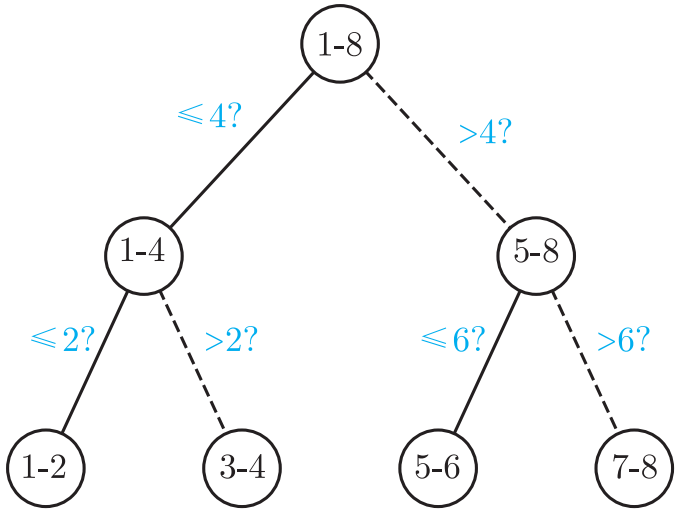


图 15-2: 二分搜索树的示意图

所以，比特的本质就是“砍一刀”。你要砍几刀才能把唯一真理找出来，这个事件的信息量就是几比特。

这就是比特（bit）的本质含义。 1 bit，就是解答一个完全公平的“是”或“否”问题（即两种可能性各占 50%）所需要的信息量。

看一枚公平硬币抛一次的信息量：$I = -\log_2(0.5) = 1$ bit。这意味着，平均而言，你需要 1 个“是/否”问题（例如“是正面吗?”）来确定结果。选择以 2 为底，让信息量的单位（比特）和我们最自然的“二分”思维直接挂钩。

当然，这不是唯一选择。以自然常数 e 为底，单位是“纳特（nat）”；以 10 为底，也有相应的单位。它们之间只差一个固定的倍数（例如，1 nat $\approx$ 1.443 bit）。选哪个底，就像你用米还是用英尺来量身高，不影响你对“谁更高”的判断。但在这门课程和计算机世界里，我们约定俗成，就用比特。

15.1.5 熵：不确定性的“平均身高”——一种数学期望

我们已经知道怎么算“单次”惊喜了（例如小王投进球）。但我们想知道的是：小王这个人，这辈子投篮平均来说能给我们带来多少惊喜?

这就得算个总账。把每种结果的惊喜度（信息量），按照它发生的概率加权平均一下。

这个“平均惊喜度”，数学家给它起了个高大上的名字叫“熵”。

随机变量的**信息熵**，就是其信息量的期望值（均值）。熵的本质，就是一种特殊的数学期望。

对于一个离散随机变量 X，它有取值 $\{x_1, x_2, ..., x_n\}$，对应概率 $\{p_1, p_2, ..., p_n\}$。那么它的熵 $H(X)$ 定义为：

$$H(X) = E[I(X)] = \sum_{i=1}^{n} p_i \cdot I(x_i) = -\sum_{i=1}^{n} p_i \log_2 p_i$$

看这个公式：$\sum p_i \cdot$ [某个值]，这正是我们熟悉的求期望的格式。所以，**熵 $H(X)$ 就是随机变量 $-\log_2 P(X)$ 的数学期望。**

回头看看我们是怎么走到这里的：从“感觉不确定”出发，想到用“信息消除不确定”，定义了与概率成反比的“信息量”，为了独立可加性选择了对数，为了单位定义了比特，最后为了描述整体不确定性，对信息量求了平均（期望）。

这个 $H(X)$，就是大名鼎鼎的（香农）信息熵。**请特别注意：熵 $H(X)$ 是随机变量 X 或其概率分布 $P(X)$ 的一个属性（一个数字特征），而不是某个特定事件 x_i 的属性。**它不关心单次的结果是惊喜还是平淡，它衡量的是这个随机系统，在长期运行中，平均每次能“产出”多少信息，或者说，在结果揭晓前，它内在的平均不确定程度有多高。

例 15.1 (伯努利分布的熵) 计算投篮命中率为 p 的伯努利随机变量 X（$X=1$ 表示命中，$X=0$ 表示未命中）的信息熵。

解答

这是一个两点分布。设 $P(X=1)=p$，则 $P(X=0)=1-p$。根据熵的定义有

$$H(X) = -p\log_2 p - (1-p)\log_2(1-p)$$

现在，代入之前三个同学的命中率如下。

- 小明 ($p=0.9$)：$H \approx -0.9 * \log_2(0.9) - 0.1 * \log_2(0.1) \approx 0.469$ bit。
- 小刚 ($p=0.5$)：$H = -0.5 * \log_2(0.5) - 0.5 * \log_2(0.5) = 1$ bit。
- 小王 ($p=0.1$)：$H \approx -0.1 * \log_2(0.1) - 0.9 * \log_2(0.9) \approx 0.469$ bit。

果然！小刚（最猜不准）的熵最高。小明和小王，虽然一个常进一个常不进，但熵值相同，不确定程度一样低。这个结果恰好是对称的。图15-3的拱形曲线展示了伯努利分布的熵完整的函数形态。当 $p=0.5$ 时不确定性达到顶峰；当概率偏向 0 或 1 时，系统变得有序，熵迅速降低。

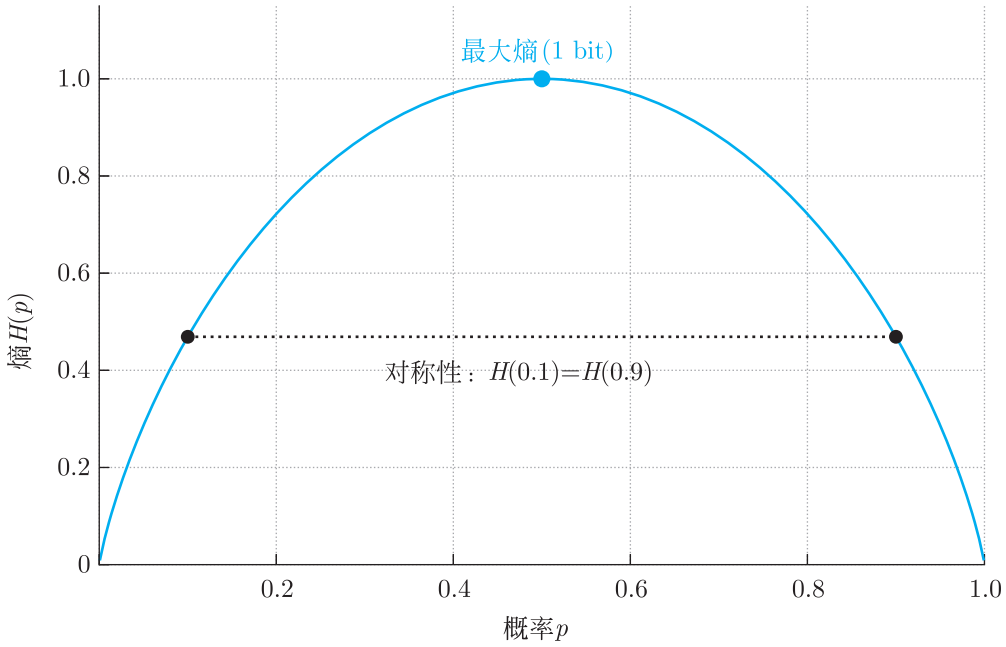


图 15-3: 伯努利分布的熵完整的函数形态

例 15.2 (三门问题中的熵) 在三门问题中，当你初选一扇门后，主持人打开一扇有山羊的门。此时，另外那扇未被你选择且未被主持人打开的门，后面有汽车的概率是 2/3，有山羊的概率是 1/3。设随机变量 Y 表示这扇门后的结果（1= 汽车，0= 山羊），求 Y 的信息熵。

解答

已知 $P(Y=1)=\frac{2}{3}$，$P(Y=0)=\frac{1}{3}$。

$$H(Y)=-\frac{2}{3}\log_2\left(\frac{2}{3}\right)-\frac{1}{3}\log_2\left(\frac{1}{3}\right)$$

计算结果为 0.918 bit。这个熵值小于 1 bit（公平硬币）。

例 15.3 (均匀分布的熵与“结果数”) 一个均匀离散随机变量 Z，等可能地取 n 个不同的值。求其熵，并讨论熵与 n 的关系。

解答

对于均匀分布，每个值的概率 $p_i=1/n$。

$$H(Z)=-\sum_{i=1}^{n}\frac{1}{n}\log_2\left(\frac{1}{n}\right)=-n\cdot\frac{1}{n}\cdot\log_2\left(\frac{1}{n}\right)=\log_2 n$$

结论非常清晰：**在均匀分布下，熵 $H(Z)=\log_2 n$，它随着可能结果数目 n 的增加而单调增加。**直觉上，结果越多，在完全公平的情况下，猜中的难度自然就越大，不确定性也就越高。

- 猜一枚公平硬币（$n=2$）：$H=\log_2 2=1$ bit。
- 猜一张扑克牌的花色（$n=4$）：$H=\log_2 4=2$ bit。需要两个“是/否”问题才能确定（比如：“是红色吗?”，“是方块吗?”）。
- 猜一副扑克牌中具体哪一张（$n=54$）：$H=\log_2 54\approx 5.75$ bit。

15.1.6 熵的另一个视角：最优编码的平均长度

信息熵还有一个很实用的解释：**它等于对随机变量结果进行最优二进制编码时，所需的平均码长的下限。**

想象你要给一个地方每天的天气发短信报告，天气只有“晴”、“雨”、“雪”三种。如果它们出现的概率不等，例如 $P(\text{晴})=0.5$，$P(\text{雨})=0.3$，$P(\text{雪})=0.2$。为了节省短信费（每个汉字或字母都花钱），你想用最短的二进制串（0 和 1）来编码天气。

一个聪明的编码策略是：给出现概率高的天气（晴）分配一个较短的码字，给出现概率低的天气（雪）分配一个较长的码字，如下。

- 晴—0。
- 雨—10。
- 雪—11。

这样，平均发送一个天气报告所需的码长（即平均编码长度）就是：

$$0.5\times 1+0.3\times 2+0.2\times 2=1.5\text{ bit}$$

你可以证明，任何无歧义的编码方案（即收到编码后能唯一还原出原始消息），其平均码长都不会低于这个随机变量的熵。计算一下这个分布的熵为

$$H=-0.5\log_2(0.5)-0.3\log_2(0.3)-0.2\log_2(0.2)\approx 1.485\text{ bit}$$

我们的平均码长（1.5 bit）非常接近这个熵值（1.485 bit）。**熵，就是这个“最短平均码长”的理论极限。**它告诉我们，为了描述这个随机现象所产生的结果，你“至少”需要多少比特的信息。

这个道理，其实如果你学过莫尔斯码（Morse Code）你就懂了。为什么在莫尔斯码里，字母 E 只是一个点（·），而字母 Q 却是“哒哒滴哒”（– – ·–）？因为 E 最常用！常用的东西，名字一定要短，说话才省力气；不常用的东西，名字长点无所谓。熵，就是那个“省力气的极限”。它告诉你，如果按照最完美的方式去压缩信息，每句话平均“最少”得用多少个字。少于这个数？那你就一定会丢字，话就传不清楚了。

15.1.7 常见分布的信息熵举例

为了让你对不同分布的熵有个“数量感”，我们来看几个经典分布（不要求记住公式，体会其直觉）。

考虑以下分布，在不精确计算的情况下，凭直觉判断哪个分布的熵可能更大，并简单解释。

(1) **泊松分布** $Pois(\lambda)$：描述单位时间内随机事件发生次数的分布。当 λ 很小时（如 0.1），分布集中在 0 和 1，熵较小。当 λ 增大，分布变得更加分散和“平坦”，熵会增大，并趋近于一个与 λ 相关的值。直觉：事件平均发生率越高，可能的结果（次数）范围越广，不确定性（熵）倾向于更大。

(2) **几何分布** $Geom(p)$：描述第一次成功所需的伯努利试验次数。成功概率 p 越大，我们预期很快成功，分布集中在前面几个数，熵较小。p 越小（例如 0.1），我们可能需要等待很久，分布有一个长长的尾巴，熵反而更大。直觉：成功越难，你越不确定究竟要等多久，不确定性越大。

(3) **二项分布** $Binom(n,p)$：描述 n 次独立伯努利试验的成功次数。当 $p=0.5$ 时，分布最对称，熵达到给定 n 下的最大值。当 p 接近 0 或 1 时，分布集中在两端，熵变小。直觉：胜负最不明时（五五开），不确定性最大。

这些例子告诉我们，熵的大小不仅取决于取值范围的宽窄（如均匀分布的 n），更取决于概率质量的集中程度。分布越“集中”（尖峰），熵越小；分布越“分散”（平坦），熵越大。

15.1.8 熵的性质与最大熵原理

通过计算，我们实际上已经触碰到了熵的几个核心性质：

(1) **非负性**：$H(X)\geq 0$。不确定性最小就是 0，没有“负的不确定性”。（注意：对于连续变量，我们使用‘微分熵’，它其实是可以为负数的，代表分布非常集中。但为了大家理解方便，本章如果不加特殊说明，我们主要讨论离散情况下的熵，它是严格非负的。）

(2) **确定性事件**：如果某个结果概率为 1（其他为 0），则 $H(X)=0$。例如“太阳从东边升起”，其熵为 0，毫无不确定性。

(3) **对称性**：熵只依赖于概率分布 $(p_1,p_2,...,p_n)$，而不依赖于这些概率具体对应哪个取值。把“正-反”标签互换，熵不变。例如，一枚正面朝上概率为 0.8 的硬币，与一枚正面朝上概率为 0.2 的硬币（此时可视为将上一枚硬币的“正面”标签换给了概率为 0.2 的结果），两者的熵是相同的。

(4) **极值性（最大熵原理）**：对于有 n 个可能结果的随机变量，**当所有结果概率相等（即均匀分布）时，熵取最大值** $\log_2 n$。

最后一条，藏着一种高级的人生智慧：知之为知之，不知为不知。

假如你只知道骰子有 6 个面，其他什么也不知道。那你该怎么猜各面的概率？

最诚实的做法是猜大家都是 1/6。如果你非要猜“1 点”概率大，那你就是在加戏——你在没有证据的情况下，引入了额外的偏见。

所谓最大熵原理，通俗来说就是：在证据不足的时候，保留最大的可能性，绝不瞎猜，绝不加戏。这是数学给我们的最客观的建议。

在不同的条件下，最大熵原理有对应的分布：

(1) **一无所知**。我只知道一个随机变量有 n 个可能取值，除此之外一无所知。此时，最合理的假设就是均匀分布（熵最大）。因为我没有理由认为任何一个结果比另一个更特殊。

(2) **知道期望值**。假设我知道一个取值为正实数的随机变量的期望值必须是一个固定数 μ。在所有满足 $E[X] = \mu$ 的分布中，**指数分布**是熵最大的分布。

(3) **知道期望和方差**。如果我知道一个实值随机变量的期望是 μ，方差是 σ^2。在所有满足这两个矩约束的分布中，**正态分布**是熵最大的分布。

在机器学习中，最大熵原理提供了一种强大的“无偏见”建模框架。当我们从数据或经验中获知一些宏观的、平均的性质（如均值、方差）后，如果我们不想引入任何额外的、没有依据的假设，那么选择最大熵分布就是最科学的做法。这个原理在自然语言处理、统计物理和机器学习中都有着深远的影响。

举个例子，你正在训练一个神经网络来识别图片。如果模型学会了识别猫，但对狗和兔子一无所知，你希望它怎么做?

你希望它在面对狗和兔子时，输出的概率是 50/50（一脸迷茫，熵最大），而不是自作聪明地喊出“这是猫!”（盲目自信，熵低）。

让熵最大化，本质上就是强制模型：把所有你不知道的事情，公平地视为每种都有可能。这是最安全的策略，也是最客观的“无知”。在深度学习里，这能极大地防止模型“死记硬背”（过拟合）——熵最大，就是偏见最小。

15.1.9 常见的“坑”

学到这儿，你可能会有几个地方觉得别扭。

(1) **概率为 0 怎么办?** 公式里有个 $p_i \log_2 p_i$，如果某个 $p_i = 0$，$0 \times \log_2(0)$ 怎么算? 我们定义 $0 \log_2 0 = 0$。从极限角度看也说得通：当 $p \to 0^+$ 时，$p \log_2 p \to 0$（趋近速度比 log 发散更快），所以这个定义和极限行为一致。你可以这样理解：一个根本不可能出现的结果，自然不会贡献任何信息量，在求平均时也应被忽略。

回到现实想一想：如果今天不可能有外星人入侵地球（概率为 0），那么“没有外星人入侵”这件事，需要向你汇报吗?

完全不需要。它是一句废话中的废话，连 1 bit 的流量都不配占用。

既然不可能发生，它就不存在于我们的沟通列表里。不存在的事，贡献的信息量自然就是 0。

(2) **熵和方差是一回事吗?** 这是最容易混淆的地方。我们来看一个具体的数值例子：

- **分布 A（尖峰长尾）**：$X = 0$ 的概率是 0.99，$X = 100$ 的概率是 0.01。

  ①先求期望 $E[X] = 0 \times 0.99 + 100 \times 0.01 = 1$。

  ② **方差**

$$\begin{aligned} \mathrm{Var}(X) &= (0-1)^2 \times 0.99 + (100-1)^2 \times 0.01 \\ &= 0.99 + 9801 \times 0.01 = 0.99 + 98.01 = 99。\end{aligned}$$

  ③ **熵** $H(X) \approx -[0.99 \times \log_2(0.99) + 0.01 \times \log_2(0.01)] \approx 0.08$ bit。

④解读：方差很大（99），因为一旦偏离均值（1），就会偏离得很远（到 100）。但熵很小（≈0.08 bit），因为你几乎百分之百确定结果是 0，非常容易猜。

- **分布 B（四数均匀）**：Y 等概率地取值为 1, 2, 3, 4。

  ①期望 $E[Y] = 2.5$。

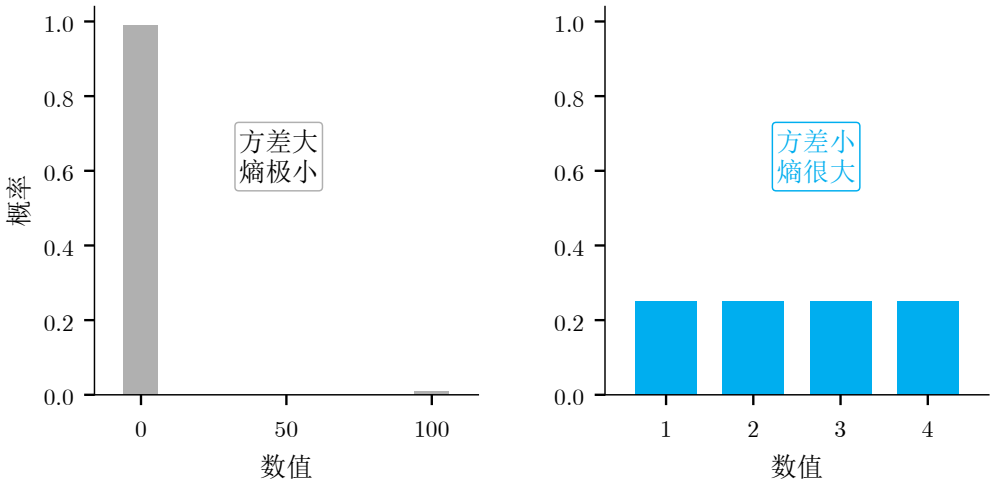
  ②方差

$$\begin{aligned}\mathrm{Var}(Y) &= [(1-2.5)^2 + (2-2.5)^2 + (3-2.5)^2 + (4-2.5)^2]/4 \\ &= 1.25。\end{aligned}$$

  ③熵 $H(Y) = \log_2 4 = 2$ bit。

  ④解读：方差不大（1.25），数值集中在 2.5 附近。但熵很大（2 bit），因为 4 个结果出现的机会完全均等，你完全猜不到下一次会是什么。

所以，**方差衡量的是取值的“分散程度”或“波动大小”；而熵衡量的是在知道具体取值前，“猜中”的困难程度。**它们刻画的是随机变量不同的侧面。一个分布可以有大的方差但小的熵（如分布 A），也可以有小的方差但大的熵（如分布 B）。图15-4的两个柱状图中直观地体现了方差与熵的区别。图15-4(a) 方差大但熵小，因为结果容易预测。图15-4(b) 方差小但熵大，因为结果完全随机。



(a) 分布A：两极分化　　(b) 分布B：均匀平坦

图 15-4: 方差与熵的区别

（3）**为什么老用比特？用自然对数行吗？**前面已经说过，选什么底只影响单位，不影响比较。这里补充一个换算公式：$\log_2 a = \frac{\ln a}{\ln 2}$。

15.1.10 信息熵与热力学熵：一个重要的澄清

这里需要澄清一个常见的混淆点：**信息熵**与你在物理课上学到的**热力学熵**，它们有什么关系？

热力学熵的公式（玻尔兹曼熵）为：

$$S = k_B \ln W$$

其中 W 是系统可能的微观状态数，k_B 是玻尔兹曼常数。

信息熵的公式为：

$$H(X) = -\sum_{i=1}^{n} p_i \log_2 p_i$$

当所有微观状态等概率时（$p_i = 1/W$），热力学熵可写为：

$$S = k_B \ln W = -k_B \sum_{i=1}^{W} \frac{1}{W} \ln\left(\frac{1}{W}\right)$$

它们在数学形式上确实非常相似。

克劳德·香农在 1948 年创立信息论时，最初想把他的概念称为“不确定性”或“信息”。他的朋友、数学家约翰·冯·诺依曼建议他使用“熵”这个词，并说：“你有两个优势：第一，没人真正知道熵到底是什么，所以你可以随意定义它；第二，在争论中，你总能占上风，因为没人知道如何反驳你。”于是，同一个词“熵”被用于两个不同但又有深刻联系的概念。

对于物理学家，他们研究的是真实世界里的东西，例如蒸汽机怎么工作、冰块为什么会融化。他们发现了一个规律：这个世界上的东西，总是会从“整齐”变得“杂乱”。例如你的书桌，你不收拾它，它就会越来越乱。他们把这种“从整齐变杂乱”的程度，用一个叫“熵”的数来度量。这就是**热力学熵**，它描述的是物理世界实实在在的“混乱程度”。

对于通信工程师和数学家，他们不研究冰块和蒸汽机，他们研究的是电话、电报怎么传消息更省事儿。他们发现，一个消息越“出人意料”，它包含的“信息”就越多。香农用一个数学上与热力学熵相似的量，来度量这种平均的“出人意料”程度；这就是**信息熵**。它描述的其实是我们脑子里的“不确定程度”。

所以，一个是从物理世界长出来的，一个是从通信问题里长出来的，只是不小心撞了名字。

它俩有没有关系?

有！而且这个关系特别有哲学味道。

你想，你要把一个乱糟糟的房间（物理熵高）整理干净（物理熵降低），你需要什么？你需要**信息**！你需要知道袜子该放哪个抽屉，书该摆哪层书架。你获取和运用这些“整理信息”的过程，本身（例如你来回走动、开抽屉）就会消耗能量、出点汗，这可能会让整个屋子的“总熵”还是增加的。

所以，**信息**能帮你降低一个地方的物理熵，但获取和处理信息本身，往往会在别处造成熵增。这说明，“信息”不是虚无缥缈的想法，它在我们这个物理宇宙里是扎扎实实有分量、有成本的。

最后，请你记住：从本章开始，往后我们嘴里说的、笔下写的所有“熵”，除非特别说明，指的都是香农的**信息熵**——那个度量“不确定程度”或“猜中难度”的数学工具。它不是热量，也不是混乱，它就是我们对一件事情“心里有多没底”的一个度量。

15.1.11 Python 实验室



Python 实验室

信息熵是数据压缩不可逾越的理论红线。动手验证一下。打开资源包中的代码`huffman_vs_entropy.py`，把你的名字或者一句情话输进去，亲自验证一下：无论多么精妙的算法，是不是真的只能无限逼近、却永远无法击穿这个理论极限？

15.1.12 总结

今天的内容，公式没几个，但思想层层递进。我希望你在合上书本后，能记住以下这几个画面。

(1) **比特的实在感**：1 bit，就是解答一个完全公平的“是”或“否”问题所需的信息。公平硬币的熵是 1 bit，意味着平均你需要问 1 个这样的问题才能知道结果（例如“是正面吗?”）。

(2) **熵是“平均惊喜度”**：它不是单次的惊讶，而是系统长期运行中，平均每次能产出多少惊讶。高度可预测的系统熵小，完全随机的系统熵大。

(3) **最大熵即最大公平**：当你一无所知时，最诚实的做法就是承认自己一无所知——赋予所有可能性相同的权重。

AI 视野 · 强化学习的“好奇心”

在训练打游戏或机器人的 AI（强化学习，如 Soft Actor-Critic）时，工程师甚至会**奖励** AI 去增加熵。这听起来很反直觉：我们不是要消除不确定性吗？其实，如果熵降得太快，AI 就会变得“固执”，只盯着眼前的一点利益（局部最优），不再尝试新动作。在这里，**熵代表了探索**。保持高熵，就是强制 AI 保持“开放心态”和“好奇心”，多去尝试那些概率低的动作，从而发现意想不到的绝招（例如 AlphaGo 的神之一手）。